

**PENGEMBANGAN *DATASET* UNTUK DETEKSI
DEEPPFAKE PADA VIDEO KUALITAS RENDAH DI
INDONESIA**

Proposal Tugas Akhir

Oleh

**Harry Truman Suhalim
18222081**



**PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG
Oktober 2025**

LEMBAR PENGESAHAN

PENGEMBANGAN *DATASET* UNTUK DETEKSI *DEEPPFAKE* PADA VIDEO KUALITAS RENDAH DI INDONESIA

Proposal Tugas Akhir

Oleh

Harry Truman Suhalim
1822081

Program Studi Sistem dan Teknologi Informasi
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung

Proposal Tugas Akhir ini telah disetujui dan disahkan
di Bandung, pada tanggal 28 Oktober 2025

Pembimbing 1

Pembimbing 2

Dr. Fetty Fitriyanti Lubis, S.T., M.T.

NIP. 118110071

Dion Tanjung, S.Kom., M.Sc., Ph.D.

NIP. 124110057

DAFTAR ISI

DAFTAR GAMBAR	iii
DAFTAR TABEL	iv
DAFTAR KODE	v
I PENDAHULUAN	1
I.1 Latar Belakang	1
I.2 Rumusan Masalah	2
I.3 Tujuan	3
I.4 Batasan Masalah	3
I.5 Metodologi	3
II STUDI LITERATUR	6
II.1 <i>Data-Centric Artificial Intelligence</i>	6
II.2 Metodologi Pengembangan <i>Dataset</i>	7
II.3 Kelompok Suku Bangsa Indonesia	10
II.4 Klasifikasi Deepfake	11
II.4.1 <i>Visual Deepfake</i>	12
II.4.2 <i>Audio Deepfake</i>	13
II.4.3 <i>Multimodal Deepfake</i>	13
II.5 <i>Dataset</i> Terdahulu	14
II.6 <i>Deepfake</i> Pada Dunia Nyata	15
III ANALISIS MASALAH	17
III.1 Analisis Kondisi Saat Ini	17
III.2 Analisis Kebutuhan	18
III.2.1 Identifikasi Masalah Pengguna	18
III.2.2 Kebutuhan Fungsional	19
III.2.3 Kebutuhan Nonfungsional	19
III.3 Analisis Pemilihan Solusi	20
III.3.1 Alternatif Solusi	20
III.3.2 Analisis Penentuan Solusi	20
IV DESAIN KONSEP SOLUSI	22
V RENCANA SELANJUTNYA	23

DAFTAR GAMBAR

II.1	Pilar Utama <i>Data-Centric AI</i>	6
II.2	Gambar Jumlah Penduduk Berdasarkan Kelompok Suku Bangsa Pada Sensus Penduduk 2010	10
II.3	Jenis-Jenis <i>Deepfake</i>	11
II.4	<i>Dataset Deepfake</i> Terdahulu	14
III.1	Model Konseptual Alur Deteksi <i>Deepfake</i> Saat Ini	17

DAFTAR TABEL

II.1	Pengelompokan 2 suku Terbesar Pada Setiap Pulau di Indonesia Beserta Kelompok Representatif Berdasarkan Sensus Penduduk 2010	11
III.1	Kebutuhan Fungsional Dataset	19
III.2	Kebutuhan Non Fungsional Dataset	20
III.3	Alternatif Solusi Dataset	20
III.4	Analisis Penentuan Solusi Dataset	21

DAFTAR KODE

BAB I

PENDAHULUAN

I.1 Latar Belakang

Perkembangan teknologi *Artificial Intelligence* menimbulkan cara baru untuk menciptakan berita hoaks melalui *deepfake*. *Deepfake* adalah teknik untuk menempatkan gambar wajah orang “sebenarnya” dalam suatu video menjadi wajah target sehingga seolah – olah target tersebut melakukan atau mengatakan hal-hal yang dilakukan orang “sebenarnya”. Menurut laporan dari Sensity AI, terjadi lonjakan kasus *deepfake* sebesar 550% sejak tahun 2019, didapatkan bahwa 90% di antaranya digunakan untuk menyebarkan disinformasi, melakukan penipuan, pencemaran nama baik, hingga pelecehan yang menargetkan kelompok rentan seperti perempuan dan anak-anak. Di Indonesia sendiri, *deepfake* sering kali digunakan untuk memprovokasi sentimen negatif dari publik. Fenomena ini menunjukkan urgensi dari pengembangan teknologi untuk dapat mendeteksi *deepfake* secara efektif.

Salah satu tantangan dalam pendeteksian *deepfake* adalah ketika suatu video *deepfake* muncul, video tersebut akan diunggah dan disebarakan melalui berbagai platform media sosial. Proses kompresi yang dilakukan pada media sosial seperti *Youtube*, *Tiktok*, *WhatsApp*, dan lain sebagainya akan menyebabkan kualitas video tersebut menurun. Kualitas video *deepfake* yang rendah akan semakin sulit untuk dideteksi, baik oleh manusia maupun oleh teknologi *AI*. Akibatnya, banyak model deteksi yang menunjukkan akurasi tinggi di lingkungan laboratorium (mencapai hampir 100%) mengalami penurunan kinerja drastis hingga hanya sekitar 65% saat dihadapkan pada skenario dunia nyata dengan video terkompresi (Alrashoud 2025, 1).

Untuk mengatasi hal tersebut, berbagai pendekatan deteksi dikembangkan oleh para peneliti. Beberapa solusi berfokus pada analisis artefak spasial dan tekstur yang tidak wajar pada wajah dengan metode deteksi *Convolutional Neural Networks* (CNNs) (Li dan Lyu 2019, 1, 2). Solusi lain menganalisis inkonsistensi temporal antar *fra-*

me video, seperti pola kedipan mata atau gerakan kepala yang tidak natural dengan menggunakan *Recurrent Neural Networks* (RNNs) (Fernandes dan Fatma 2025, 1; Alrashoud 2025, 9). Selain itu, ada metode yang lebih maju untuk mendeteksi sinyal biologis (misalnya, detak jantung melalui metode *remote Photoplethysmography* atau rPPG) yang gagal direplikasi oleh generator *deepfake* (Ciftci, Demir, dan Yin 2020, 1, 7). Pendekatan multimodal yang menganalisis sinkronisasi antara gerakan bibir (visual) dan ucapan (audio) juga menunjukkan hasil yang menjanjikan karena generator *deepfake* sering kali kesulitan menjaga kolerasi temporal antara kedua modalitas tersebut (Alrashoud 2025, 1).

Meskipun begitu, terdapat beberapa kesenjangan penelitian yang harus diperhatikan. Pertama, mayoritas model deteksi yang ada belum teruji secara komprehensif dengan video yang berkualitas rendah yang umumnya tersebar pada media sosial. Kedua, sebagian besar *dataset* yang digunakan untuk melatih model berasal dari luar negeri, sehingga masih dipertanyakan validitasnya untuk mendeteksi *deepfake* untuk konten *deepfake* yang tersebar di Indonesia (Banerjee dkk. 2024, 5; Graupner dkk. 2025, 7). Oleh karena itu, penelitian ini diusulkan untuk mengembangkan sebuah solusi yang berfokus pada deteksi *deepfake* pada video berkualitas rendah akibat kompresi, serta divalidasi dengan konten yang relevan dengan konteks Indonesia. Kebutuhan akan solusi yang andal dan efisien inilah yang menjadi motivasi utama dibalik pemilihan topik tugas akhir ini.

I.2 Rumusan Masalah

Masalah utama yang ingin diselesaikan dalam tugas akhir ini adalah belum adanya model deteksi *deepfake* yang andal dan teruji untuk menangani video berkualitas rendah dalam konteks Indonesia. Mayoritas solusi yang ada saat ini dilatih menggunakan *dataset* video resolusi tinggi dengan subjek non-Indonesia, sehingga performanya menurun drastis saat dihadapkan pada video terkompresi dan gagal mengenali karakteristik demografis lokal. Jika tidak diatasi, masyarakat akan semakin rentan terhadap ancaman disinformasi dan penipuan berbasis *deepfake*. Dalam menjawab permasalahan tersebut, penelitian ini akan berfokus pada pembuatan dataset yang representatif dan pengembangan model deteksi yang robust. Berikut adalah beberapa rumusan masalah spesifik yang akan diselesaikan

1. Bagaimana metodologi yang efektif untuk mengumpulkan dan menyeleksi video asli yang beragam dari sumber lokal Indonesia sebagai bahan dasar untuk pembuatan *dataset*?
2. Teknik pembuatan (*deepfake*) apa saja yang perlu diterapkan pada video asli

untuk menghasilkan data manipulasi yang relevan dengan ancaman saat ini, dan bagaimana proses penerapannya?

3. Bagaimana cara mensimulasikan efek kompresi media sosial secara sistematis untuk menghasilkan video berkualitas rendah yang realistis dan terukur dalam *dataset*?

I.3 Tujuan

Tugas akhir ini bertujuan untuk mengembangkan dataset untuk dapat mendeteksi video deepfake di Indonesia dengan metode pembuatan deepfake serta pengumpulan video deepfake yang beredar di sosial media.

I.4 Batasan Masalah

Berikut merupakan beberapa batasan yang ditetapkan untuk memfokuskan ruang lingkup dan memastikan hasil dari tugas akhir ini relevan dengan tujuan yang ditetapkan.

1. Tugas akhir ini dikerjakan secara berkelompok yang terdiri dari 3 orang mahasiswa, yaitu Alvin Fadhilah Akmal (NIM 18222079), Harry Truman Suhalim (NIM 18222081), dan Steven Adrian Corne (NIM 18222101). Adapun pembagian fokus dari ketiga mahasiswa tersebut ialah Alvin fokus pada antarmuka, Harry fokus pada *dataset deepfake*, dan Steven fokus pada model untuk mendeteksi *deepfake*.
2. Penelitian akan menggunakan *dataset* video yang dirancang untuk merepresentasikan konteks Indonesia. Ini mencakup pengumpulan video asli yang menampilkan wajah orang Indonesia dan pembuatan video deepfake dari bahan tersebut.

I.5 Metodologi

Tahapan yang akan dilalui selama pelaksanaan tugas akhir ini terdiri dari tiga bagian, yaitu:

1. Perumusan masalah awal
Pada tahapan ini, dilakukan identifikasi masalah awal dengan cara *brainstorming* bersama dengan seluruh anggota kelompok tugas akhir untuk menentukan masalah yang akan diangkat menjadi topik tugas akhir. Bermula dari pengamatan salah seorang anggota kelompok, terkait sulit membedakan berita mana yang hoax dan berita mana yang asli. Seluruh anggota kelompok

mengalami hal yang sama, dikarenakan berita hoax terlalu luas maka kami menyepakati untuk mendeteksi hoax berupa *deepfake*. Untuk mempelajari tentang *deepfake* terutama dalam konteks hoax kami melakukan riset lebih lanjut. Akhirnya ditemukan data dan fakta bahwa *deepfake* saat ini sering kali digunakan untuk menyebarkan hoax dan ditemukan juga beberapa jurnal yang membahas *deepfake*. Data dan informasi yang didapat dari jurnal tersebut akhirnya memperkuat masalah yang ingin kami selesaikan dikarenakan dalam beberapa jurnal disebutkan bahwa model deteksi *deepfake* yang mereka miliki belum dapat mendeteksi video dengan kualitas rendah dan juga model kurang relevan digunakan apabila konteks *deepfake* di Indonesia.

2. Pencarian dan Penulisan Studi Literatur

Penentuan teori-teori yang dirasa perlu dalam penulisan tugas akhir ini dilakukan dengan mengidentifikasi hal-hal seputar fokus yang dibahas oleh setiap anggota kelompok tugas akhir. Tugas akhir ini fokus pada dataset sehingga teori-teori yang dibutuhkan adalah teori seputar metodologi pembuatan *dataset deepfake* publik, teknik generasi *deepfake*, serta dampak dan simulasi dari kompresi video. Metodologi pembuatan *dataset* sendiri dipilih dengan tujuan untuk menyamakan *dataset* dengan konten lokal yang ada di Indonesia sehingga lebih relevan. Selain itu, dapat juga disesuaikan kualitas dari video untuk menyesuaikan dengan kondisi video disebar luaskan di sosial media. Adapun penelusuran pustaka lebih dalam terkait setiap teori yang diperlukan dilakukan melalui internet. Untuk setiap teori, dilakukan pencarian terhadap jurnal-jurnal yang membahas spesifik terkait teori tersebut. Kata kunci pencarian yang digunakan antara lain "*deepfake dataset creation*", "*face forensics*", "*video compression simulation*", dan "*generative adversarial networks for face synthesis*". Untuk setiap area, proses dimulai dengan mencari survey paper guna mendapatkan gambaran umum, lalu dilanjutkan dengan penelusuran mendalam terhadap artikel-artikel kunci yang relevan untuk dipelajari metodologinya secara detail.

3. Pengembangan *Dataset*

Pengembangan *dataset* dibuat secara manual dengan membuat *deepfake* sendiri maupun mengambil *deepfake* yang ada di sosial media. Metodologi dalam pengembangan dataset dibagi menjadi empat fase yaitu:

a. Fase Pengumpulan (*Collection*)

Pada fase ini, dilakukan pengumpulan bahan mentah untuk *dataset*. Fokus utama adalah mendapatkan data video asli yang merepresentasikan konten lokal Indonesia. Kebutuhan awal, seperti jumlah video, durasi,

dan variasi subjek, ditetapkan untuk memastikan *dataset* yang dihasilkan cukup beragam. Video terkait tokoh publik, *vlogger*, dan individu lainnya pada sosial media diunduh dengan kualitas tinggi, video *deepfake* yang tersebar pada sosial media juga dikumpulkan.

- b. Fase Generasi dan Pemrosesan (*Construction*) Setelah bahan mentah terkumpul, dilakukan proses pembuatan data *deepfake*. Fase ini diawali dengan penggunaan video asli untuk menghasilkan video manipulasi menggunakan beberapa teknik, seperti *face swapping* dan *lip-sync*, dengan perangkat lunak open-source untuk menciptakan variasi artefak. Setelah itu, dilakukan simulasi kompresi menggunakan *tools* seperti FFmpeg untuk menurunkan kualitas video secara terkontrol, sehingga menghasilkan versi berkualitas rendah yang realistis.

- c. Fase Pelabelan (*Labeling*)

Pada fase ini, setiap data yang telah diproses akan diberi label informatif untuk memberikan konteks bagi model *machine learning*. Setiap video akan diklasifikasikan dengan label utama (asli atau palsu). Selanjutnya, sebuah file metadata akan dibuat untuk mencatat informasi yang lebih detail untuk setiap data, seperti ID video, label utama, jenis manipulasi yang digunakan (jika palsu), dan tingkat kompresi yang diterapkan.

- d. Fase Validasi (*Transition*)


Setelah pelabelan selesai, *dataset* divalidasi untuk memastikan kualitas dan integritasnya. Dilakukan pemeriksaan silang secara acak terhadap sampel data untuk memastikan pelabelan sudah akurat. Selain itu, diperiksa keseimbangan antara kelas asli dan palsu serta antara data berkualitas tinggi dan rendah. Tujuannya adalah digunakan untuk melakukan perbaikan minor pada *dataset* sebelum digunakan untuk pelatihan model.

BAB II

STUDI LITERATUR

II.1 *Data-Centric Artificial Intelligence*

Data-centric artificial intelligence adalah disiplin yang diterapkan untuk merencanakan data yang digunakan dalam membangun sistem AI secara sistematis. Ini merupakan perubahan dari yang sebelumnya yang berupa *model-centric*, peneliti fokus mengubah model sambil membiarkan data tetap. Keberhasilan dalam AI tentu bergantung pada kualitas data yang dimiliki, dalam konteks *deepfake* terutama di Indonesia, sumber data yang relevan tentu dibutuhkan pula. Kualitas data sangat memengaruhi kinerja model dalam mendeteksi *deepfake* pula, model tentu sangat penting dalam mendeteksi *deepfake* tetapi *dataset* yang baik juga tidak kalah penting. Oleh karena itu, dibutuhkan *dataset* yang baik untuk mendukung pembentukan model yang baik pula.



Gambar II.1 Pilar Utama *Data-Centric AI*

Berdasarkan gambar II.1, terdapat tiga pilar utama dari *data-centric AI*. Pada penelitian ini, terdapat dua pilar utama dari *data-centric AI* yang difokuskan yaitu Pengembangan Data Pelatihan (*Training Data Development*) dan Pengembangan Data Inferensi (*Inference Data Development*). Tahapan dalam Pengembangan Data Pelatihan (*Training Data Development*) terdiri dari :

1. Pengumpulan Data (*Data Collection*)

Pengumpulan data adalah proses mengumpulkan dan memperoleh data da-

ri berbagai sumber. Proses ini secara fundamental menentukan kualitas dan kuantitas data. Proses ini sangat bergantung pada *domain knowledge* untuk memastikan data yang dikumpulkan relevan, representatif, dan selaras dengan tujuan pemangku kepentingan.

2. Pelabelan Data (*Data Labeling*)

Pelabelan data adalah proses memberikan satu atau lebih *tag* atau label deskriptif ke *dataset*. Proses ini memungkinkan algoritma untuk belajar dari data dan membuat prediksi. Pelabelan memainkan peran krusial dalam memastikan bahwa model yang dilatih pada data tersebut secara akurat mencerminkan intensi atau harapan manusia.

3. Augmentasi Data (*Data Augmentation*)

Augmentasi data adalah teknik untuk meningkatkan ukuran (*size*) dan keragaman (*diversity*) data dengan cara membuat variasi buatan dari data yang ada. Teknik ini seringkali dapat meningkatkan kinerja model. Augmentasi data sangat penting karena algoritma pembelajaran mesin modern, terutama *deep learning*, seringkali membutuhkan data dalam jumlah besar untuk belajar secara efektif.

Sedangkan, tahapan dari Pengembangan Data Inferensi (*Inference Data Development*) terdiri dari :

1. Evaluasi *Out-of-Distribution*

Evaluasi *Out-of-Distribution* mengacu pada penggunaan sekumpulan sampel data yang mengikuti distribusi yang berbeda dari yang diamati dalam data pelatihan.

2. Pemilahan Data (*Data Slicing*)

Data slicing adalah bagian dari evaluasi *in-distribution*.

Ini didefinisikan sebagai proses mempartisi membagi *dataset* menjadi sub-populasi yang relevan dan mengevaluasi kinerja model pada setiap sub-populasi tersebut secara terpisah (Zha dkk. 2023).

II.2 Metodologi Pengembangan *Dataset*

Pengembangan dataset dalam *machine learning* modern semakin diakui sebagai proses yang krusial dan kompleks, yang membutuhkan metodologi terstruktur untuk memastikan transparansi, akuntabilitas, dan tanggung jawab etis. Mengambil analogi dari lembar data di industri elektronik yang merinci karakteristik komponen, (Gebru dkk. 2021) mengusulkan agar setiap dataset disertai dengan lembar data serupa. Tujuan utamanya adalah untuk meningkatkan transparansi dan akuntabilitas

dalam komunitas *machine learning*. Metodologi ini dirancang untuk melayani dua pemangku kepentingan utama: pembuat dataset dan konsumen *dataset*. Bagi pembuat, proses ini mendorong refleksi yang cermat terhadap asumsi, potensi risiko, dan implikasi penggunaan *dataset*; proses refleksi ini sengaja dirancang untuk tidak otomatis. Bagi konsumen, lembar data menyediakan informasi yang diperlukan untuk membuat keputusan yang tepat tentang penggunaan *dataset* dan menghindari penyalahgunaan (Gebru dkk. 2021).

Melengkapi kerangka kerja dokumentasi tersebut, (Orr dan Crawford 2024) mengeksplorasi praktik dan proses penciptaan *dataset* yang bertanggung jawab dari perspektif pembuatnya. Melalui wawancara mendalam dengan 18 pembuat *dataset* terkemuka, mereka mengidentifikasi bahwa pekerjaan *dataset* seringkali terfragmentasi, kurang dihargai, dan para pembuatnya sering belajar dari kesalahan secara terisolasi (Orr dan Crawford 2024). Studi ini menyajikan tujuh rekomendasi metodologis utama yang berasal dari pengalaman praktis para pembuat *dataset*, yang memberikan panduan tentang bagaimana melaksanakan siklus hidup yang diidentifikasi oleh (Gebru dkk. 2021).

Studi Orr dan Crawford menyajikan tujuh rekomendasi metodologis utama yang berasal dari pengalaman praktis para pembuat *dataset*. Rekomendasi ini memberikan panduan praktis tentang bagaimana melaksanakan tahapan siklus hidup yang diidentifikasi oleh Gebru et al.

1. Diversifikasi dan Audit

Metodologi pengembangan harus secara aktif mendiversifikasi *dataset* tidak hanya secara demografis tetapi juga dalam atribut data untuk menghindari sinyal palsu. Ini harus disertai dengan audit menyeluruh untuk melaporkan distribusi data secara jujur.

2. Upayakan Kualitas Tinggi

Kualitas adalah pilar metodologis, yang dicapai melalui validasi data dan inspeksi manual, serta proses kurasi dan pembersihan yang disiplin.

3. Mulai Lebih Awal dan Iterasi

Proses pengembangan *dataset* bersifat iteratif. Para pembuat merekomendasikan untuk menerima kesalahan sebagai hal yang tak terhindarkan dan menggunakan *rapid iteration* untuk perbaikan berkelanjutan, terutama saat bekerja dengan *crowd worker*.

4. Dokumentasi Terbuka dan Komunikasi Keterbatasan

Menegaskan kembali pentingnya "Datasheets", Orr dan Crawford menyoroti perlunya mendokumentasikan secara terbuka untuk mengatasi "documenta-

tion debt” dan memastikan reproduktifitas. Ini juga mencakup komunikasi berkelanjutan tentang keterbatasan bahkan setelah *dataset* dirilis.

5. Desain Berpusat Pengguna dan Pembatasan Penggunaan

Metodologi yang bertanggung jawab menuntut pembuat untuk mendefinisikan kasus penggunaan yang dimaksud dan secara aktif mengantisipasi potensi bahaya atau penggunaan yang tidak diinginkan. Jika risiko penyalahgunaan terlalu tinggi, pembuat harus berani untuk tidak merilis *dataset*.

6. Atasi Privasi dan Persetujuan

Pembuat *dataset* didesak untuk mempertimbangkan privasi melampaui kewajiban hukum. Ini termasuk praktik seperti *scrapping* yang ”sopan” (*polite*) dan mengevaluasi kembali asumsi bahwa data yang tersedia untuk umum menyiratkan persetujuan untuk digunakan dalam pelatihan model.

7. Buat *Dataset* yang Dibutuhkan

Terakhir, para praktisi merekomendasikan untuk tidak hanya bergantung pada data yang ditemukan. Metodologi yang kuat harus mencakup upaya untuk membuat *dataset* baru yang sesuai *fit-for-purpose*, meskipun membutuhkan lebih banyak sumber daya.

II.3 Kelompok Suku Bangsa Indonesia

Tabel 2
Jumlah dan Persentase Penduduk Menurut Kelompok Suku Bangsa

Kelompok Suku Bangsa	Jumlah	Persen	Ranking
(1)	(2)	(3)	(4)
Suku asal Aceh	4 091 451	1,73	14
Batak	8 466 969	3,58	3
Nias	1 041 925	0,44	30
Melayu	5 365 399	2,27	10
Minangkabau	6 462 713	2,73	7
Suku asal Jambi	1 415 547	0,6	25
Suku asal Sumatera Selatan	5 119 581	2,16	10
Suku asal Lampung	1 381 660	0,58	26
Suku asal Sumatera Lainnya	2 204 472	0,93	21
Betawi	6 807 968	2,88	6
Suku asal Banten	4 657 784	1,97	11
Sunda	36 701 670	15,5	2
Jawa	95 217 022	40,22	1
Cirebon	1 877 514	0,79	24
Madura	7 179 356	3,03	5
Bali	3 946 416	1,67	15
Sasak	3 173 127	1,34	16
Suku Nusa Tenggara Barat lainnya	1 280 094	0,54	27
Suku asal Nusa Tenggara Timur	4 184 923	1,77	12
Dayak	3 009 494	1,27	17
Banjar	4 127 124	1,74	13
Suku asal Kalimantan lainnya	1 968 620	0,83	22
Makassar	2 672 590	1,13	20
Bugis	6 359 700	2,69	8
Minahasa	1 237 177	0,52	29
Gorontalo	1 251 494	0,53	28
Suku asal Sulawesi lainnya	7 634 262	3,22	4
Suku asal Maluku	2 203 415	0,93	22
Suku asal Papua	2 693 630	1,14	19
Cina	2 832 510	1,2	18
Asing/Luar Negeri	162 772	0,07	31
Total	236 728 379	100	

Catatan: Cina dan Asing/Luar Negeri adalah penduduk yang berkewarganegaraan Indonesia

Gambar II.2 Gambar Jumlah Penduduk Berdasarkan Kelompok Suku Bangsa Pada Sensus Penduduk 2010

Berdasarkan data dari Sensus Penduduk 2010 pada gambar II.2, didapat bahwa Indonesia memiliki kelompok suku bangsa yang sangat beragam (Badan Pusat Statistik 2012). Oleh karena itu untuk merepresentasikan Indonesia diputuskan untuk mengambil 2 suku terbanyak di setiap pulau di Indonesia beserta kelompok suku representatif lainnya.

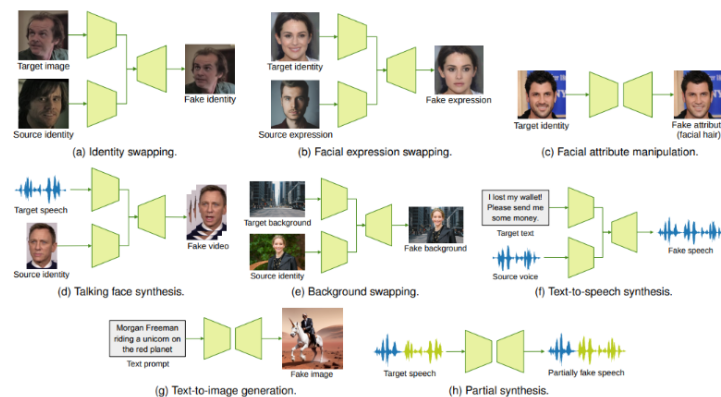
Berikut ini adalah tabel pengelompokan 2 suku terbesar pada setiap pulau di Indonesia beserta kelompok representatif yang akan digunakan.

Tabel II.1 Pengelompokan 2 suku Terbesar Pada Setiap Pulau di Indonesia Beserta Kelompok Representatif Berdasarkan Sensus Penduduk 2010

Wilayah	Suku	Persentase
Jawa	Jawa	40,22%
	Sunda	15,5%
Sumatra	Batak	3,58%
	Minangkabau	2,73%
Kalimantan	Banjar	1,74%
	Dayak	1,27%
Sulawesi	Bugis	2,69%
	Makassar	1,13%
Bali & Nusa Tenggara	Bali	1,67%
	Sasak	1,34%
Kelompok Representatif	Cina	1,2%

Berdasarkan tabel II.1, dengan strategi pengambilan sampel berstrata berdasarkan wilayah ini, kesebelas kelompok suku bangsa tersebut dipilih untuk memastikan dataset yang dibangun dapat mewakili keragaman suku utama di Indonesia secara lebih berimbang, tidak hanya terkonsentrasi pada populasi mayoritas.

II.4 Klasifikasi Deepfake



Gambar II.3 Jenis-Jenis *Deepfake*

Berdasarkan survei komprehensif oleh (Croitoru dkk. 2024), media *deepfake* didefinisikan sebagai file gambar, video, atau audio yang diubah secara digital atau dibuat dari awal menggunakan alat *AI*. Tinjauan literatur dalam penelitian tersebut

secara khusus mencakup semua jenis media *deepfake*, yang dikategorikan ke dalam empat domain utama: gambar, video, audio, dan konten multimodal (*audio-visual*). Subbab berikut akan menguraikan klasifikasi ini secara rinci, dimulai dari *deepfake* visual (yang mencakup gambar dan video), diikuti oleh *deepfake* audio, dan *deepfake* multimodal. Prosedur-prosedur ini, yang diilustrasikan pada Gambar II.3, dapat bersifat *domain-agnostic* (berlaku di berbagai jenis media) atau *domain-specific* (hanya berlaku untuk media tertentu saja).

II.4.1 *Visual Deepfake*

Visual deepfake merujuk pada media gambar atau video yang telah diubah atau dibuat dari awal menggunakan alat AI. Tujuannya adalah untuk memanipulasi konten visual, paling sering menargetkan wajah manusia. Berikut ini adalah jenis-jenis utama visual *deepfake*:

1. *Identity Swapping (Face Swapping)*

Ini adalah jenis *deepfake* yang paling umum, identitas (wajah) seseorang dalam gambar atau video target diganti dengan identitas orang lain (sumber). Teknik ini berusaha mempertahankan atribut non-identitas dari target, seperti ekspresi wajah.

2. *Facial Expression Swapping (Face Reenactment)*

Berbeda dengan *face swapping*, teknik ini tidak mengubah identitas seseorang, melainkan memodifikasi ekspresi atau emosi wajah. Dalam domain video, ini sering disebut *face reenactment*, gerakan wajah target diubah, seringkali meniru gerakan dari video sumber.

3. *Facial Attribute Manipulation*

Teknik ini berfokus pada pengubahan atribut semantik tertentu pada wajah sambil mempertahankan identitas aslinya. Atribut yang umum diubah meliputi usia, jenis kelamin, warna kulit, atau gaya rambut.

4. *Text-to-Image/Video Generation*

Dengan kemajuan model difusi, *deepfake* visual kini dapat dibuat hanya dengan menggunakan perintah teks (*prompt*). Pengguna dapat menentukan detail seperti nama orang, atribut wajah, dan tindakan yang harus dilakukan.

5. *Background Swapping*

Jenis manipulasi ini mengubah pemandangan latar belakang pada konten visual, biasanya dengan mensegmentasi orang di latar depan dan menempatkannya di latar belakang yang baru (Croitoru dkk. 2024).

II.4.2 *Audio Deepfake*

Audio deepfake adalah file audio yang dimanipulasi atau dihasilkan oleh AI. Tujuannya sering kali untuk meniru suara seseorang atau mengubah konten ucapan. Jenis-jenis utama audio *deepfake* yang dibahas meliputi:

1. *Identity Swapping (Voice Conversion)*

Dalam konteks audio, ini dikenal sebagai *voice conversion* atau *voice swapping*. Tujuannya adalah untuk mengubah warna suara dan irama dari seorang pembicara agar terdengar seperti pembicara lain, sambil tetap mempertahankan isi pidato aslinya.

2. *Emotion Swapping*

Teknik ini mengubah emosi dalam sebuah rekaman ucapan (misalnya, dari tenang menjadi marah) tanpa mengubah isi konten atau identitas pembicara.

3. *Text-to-Speech (TTS) Synthesis*

Ini adalah proses pembuatan audio *deepfake* menggunakan model *machine learning* untuk sintesis ucapan dari input teks. Model TTS modern dapat menghasilkan ucapan yang terdengar alami dan mampu meniru suara identitas sumber tertentu.

4. *Partial Synthesis*

Jenis manipulasi ini hanya mengubah sebagian dari file media. Dalam domain audio, ini berarti mengubah sebagian kata dalam sebuah ucapan, sambil memastikan identitas target tetap terjaga di seluruh klip audio (Croitoru dkk. 2024).

II.4.3 *Multimodal Deepfake*

Multimodal deepfake adalah manipulasi yang melibatkan lebih dari satu jenis media secara bersamaan. Berikut ini adalah contoh dari multimodal *deepfake*:

1. *Talking Face Synthesis*

Ini adalah contoh utama dari *deepfake* multimodal, yang digambarkan sebagai prosedur kompleks untuk menghasilkan file *audio-video* dari wajah yang berbicara. Proses ini dapat dikondisikan oleh berbagai input seperti teks, audio, atau video. Tujuannya adalah untuk menghasilkan video gerakan bibir, ekspresi wajah, gerakan kepala, dan ucapan yang dihasilkan semuanya konsisten dan tersinkronisasi (Croitoru dkk. 2024).

II.5 Dataset Terdahulu

Table 1. Fundamental information of existing deepfake video detection datasets

No.	Dataset	Release	Source	Real		Fake	
				Video	Frame	Video	Frame
[4]	FaceForensics	Mar 2018	YouTube	1,004	519.127K	1,004	521.406K
[5]	FaceForensics++	Jan 2019	YouTube	1,000	509.914K	4,000	18M
[6]	DeepFakeDetection	Sep 2019	Paid participants	363	315.4K	3,068	2242.7K
[7]	UADFV	Nov 2018	YouTube	49	-	49	-
[8]	DeepfakeTIMIT	Dec 2018	YouTube	-	-	620	68K
[9]	Celeb-DF	Sep 2019	YouTube	408	-	795	-
[10]	Celeb-DFv2	Nov 2019	YouTube	590	230.100K	5,639	2199.210K
[11]	DFDC preview	Oct 2019	Paid participants	1,131	-	4,119	-
[12]	DFDC	Jun 2020	Paid participants	23.654K	-	104.500K	-
[13]	DeeperForensics-1.0	Jan 2020	Paid participants and YouTube	50K	12.6M	10K	5M
[14]	WildDeepfake	Oct 2020	Collected from online	3,805	440.5k	3,509	739.6k
[15]	KoDF	Mar 2021	Volunteer participants	62.166K	-	175.776K	-
[16]	ForgeryNet	Jul 2021	-	99.630K	1,438.201K	121.617K	1,457.861K

Gambar II.4 Dataset Deepfake Terdahulu

Gambar II.4 menyajikan informasi fundamental mengenai *dataset-dataset* deteksi video *deepfake* yang sudah ada. *Dataset-dataset* ini, yang dirilis antara Maret 2018 hingga Juli 2021, digunakan secara luas dalam penelitian deteksi *deepfake*. Sumber video untuk *dataset* ini bervariasi, termasuk YouTube, partisipan berbayar, video yang dikumpulkan dari internet secara umum, dan partisipan sukarela. Berikut adalah daftar *dataset* yang disebutkan beserta beberapa detailnya:

1. *FaceForensics*: Dirilis Maret 2018, bersumber dari *YouTube*, berisi 1.004 video asli dan 1.004 video palsu.
2. *FaceForensics++*: Dirilis Januari 2019, bersumber dari *YouTube*, berisi 1.000 video asli dan 4.000 video palsu.
3. *DeepFakeDetection*: Dirilis September 2019, bersumber dari partisipan berbayar, berisi 363 video asli dan 3.068 video palsu.
4. *UADFV*: Dirilis November 2018, bersumber dari *YouTube*, berisi 49 video asli dan 49 video palsu.
5. *DeepfakeTIMIT*: Dirilis Desember 2018, berisi 620 video palsu. Jumlah video asli tidak disebutkan dalam tabel ini.
6. *Celeb-DF*: Dirilis September 2019, bersumber dari *YouTube*, berisi 408 video asli dan 795 video palsu.
7. *Celeb-DFv2*: Dirilis November 2019, bersumber dari *YouTube*, berisi 590 video asli dan 5.639 video palsu.
8. *DFDC preview*: Dirilis Oktober 2019, bersumber dari partisipan berbayar, berisi 1.131 video asli dan 4.119 video palsu.
9. *DFDC*: Dirilis Juni 2020, bersumber dari partisipan berbayar, berisi 23.654 video asli dan 104.500 video palsu.
10. *DeeperForensics-1.0*: Dirilis Januari 2020, bersumber dari partisipan berbayar dan *YouTube*, berisi 50.000 video asli dan 10.000 video palsu.

11. *WildDeepfake*: Dirilis Oktober 2020, bersumber dari koleksi online, berisi 3.805 video asli dan 3.509 video palsu.
12. *KoDF*: Dirilis Maret 2021, bersumber dari partisipan sukarela, berisi 62.166 video asli dan 175.776 video palsu.
13. *ForgeryNet*: Dirilis Juli 2021, berisi 99.630 video asli dan 121.617 video palsu (Sohan, Solaiman, dan Hasan 2023).

II.6 *Deepfake* Pada Dunia Nyata

Kehadiran video yang dihasilkan oleh kecerdasan buatan (*AI*) di media sosial menimbulkan tantangan baru bagi deteksi *deepfake*. Detektor yang dilatih seringkali gagal melakukan generalisasi ke skenario dunia nyata. Salah satu faktor kunci di balik kesenjangan ini adalah kompresi agresif dan *proprietary* yang diterapkan oleh platform seperti *YouTube* dan *Facebook*. Proses ini secara signifikan merusak fitur forensik tingkat rendah yang penting untuk membedakan konten asli dari media yang dimanipulasi. Meskipun *State-of-the-Art (SoA)* metode deteksi *deepfake*, seperti yang berbasis *CNN (ResNet50, DenseNet, EfficientNet, XceptionNet)* dan *Vision Transformer (ViT)*, menunjukkan kinerja sangat baik di bawah kondisi laboratorium, kinerjanya menurun drastis ketika diterapkan pada *deepfake* yang dibagikan di media sosial.

Kompresi dan pengubahan ukuran pada media sosial dilakukan untuk mengatasi kendala *bandwidth* dan penyimpanan yang sangat relevan di Indonesia. Meskipun langkah-langkah ini mengurangi ukuran file, mereka juga secara signifikan menurunkan kualitas fitur forensik yang penting untuk deteksi. Kompresi ini dapat menghilangkan atau mengaburkan artefak halus yang diperkenalkan selama proses pembuatan *deepfake*, sehingga menyulitkan detektor untuk mengidentifikasi manipulasi secara akurat. Fenomena ini telah diamati secara konsisten dalam penelitian sebelumnya.

Untuk menjembatani kesenjangan dengan aplikasi dunia nyata, beberapa upaya telah dilakukan, terutama dalam domain gambar. Pendekatan seperti membuat *dataset* dengan gambar yang sudah dikompresi atau menggunakan *fine-tuning* untuk mengadaptasi model pada data terkompresi telah diusulkan. Namun, replikasi transformasi kompresi platform untuk video dalam skala besar tetap menjadi tantangan karena keterbatasan *API* dan kendala berbagi data. Artikel ini mengusulkan kerangka kerja emulasi untuk mereplikasi artefak kompresi dan *resizing* video platform secara lokal, sebagai solusi untuk menghasilkan data pelatihan yang lebih realistis

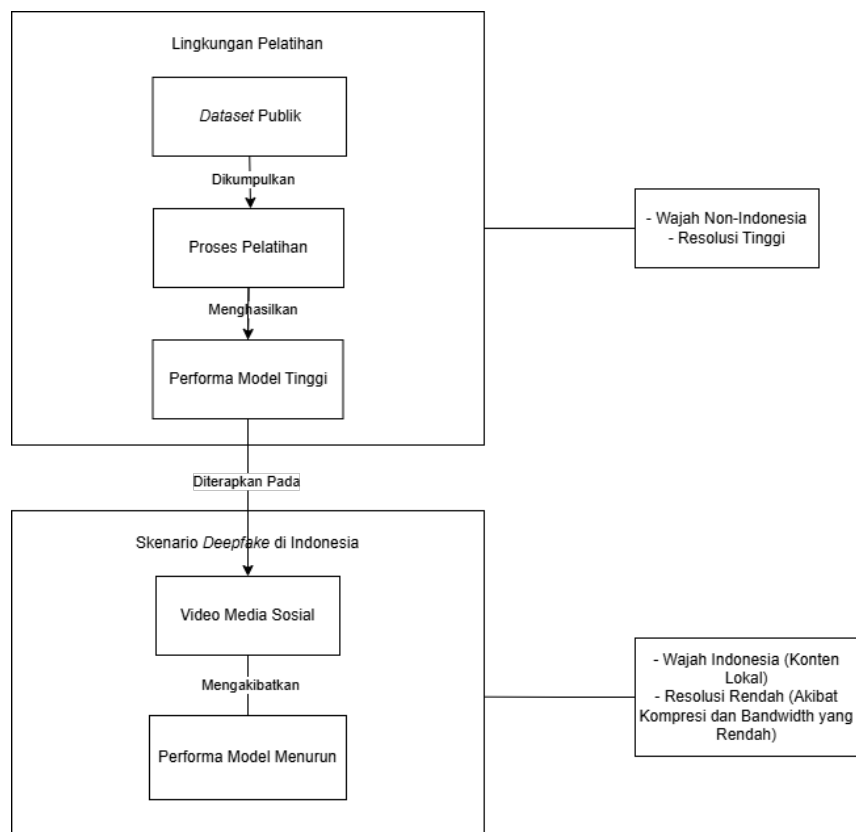
tanpa memerlukan akses *API* langsung (Montibeller dkk. 2025).

BAB III

ANALISIS MASALAH

III.1 Analisis Kondisi Saat Ini

Sistem deteksi *deepfake* yang ada saat ini dapat dimodelkan sebagai sebuah alur proses yang bergantung penuh pada ketersediaan data pelatihan. Gambar III.1 menggambarkan model konseptual dari alur kerja deteksi *deepfake* yang umum digunakan saat ini di Indonesia.



Gambar III.1 Model Konseptual Alur Deteksi *Deepfake* Saat Ini

Alur kerja dari model konseptual dimulai dari *dataset* publik yang telah banyak di-

tinjau dalam studi literatur, seperti FaceForensics , Celeb-DFv2 , dan DFDC (Sohan, Solaiman, dan Hasan 2023). Sebagian besar dataset ini memiliki karakteristik utama berupa wajah non-Indonesia dan video dengan resolusi yang masih tergolong tinggi. Dataset ini yang kemudian digunakan untuk proses pelatihan , dilanjutkan dengan arsitektur *deep learning* belajar mengenali pola dan artefak manipulasi. Hasil dari proses ini adalah sebuah model deteksi yang menunjukkan performa sangat tinggi di lingkungan laboratorium.

Namun, seperti yang telah diidentifikasi dalam studi literatur , masalah fundamental muncul apabila model tersebut digunakan untuk mendeteksi *deepfake* dalam konteks dunia nyata di Indonesia. Video-video di Indonesia berisi orang-orang lokal (Indonesia) dan, yang lebih penting, mengalami kompresi agresif akibat penyebaran di sosial media serta *bandwidth* internet yang tidak merata.

Kondisi ini sejalan dengan temuan (Montibeller dkk. 2025), yang menyatakan bahwa kompresi video secara signifikan merusak fitur forensik tingkat rendah, sehingga menyulitkan detektor. Akibat dari kesenjangan data (distribusi *out-of-distribution*) antara data latih (resolusi tinggi, non-Indonesia) dengan data di lapangan (resolusi rendah, Indonesia) , performa model yang sebelumnya tinggi dapat menurun drastis. Kondisi inilah yang menjadi justifikasi utama perlunya pengembangan *dataset* baru yang dapat menjembatani kesenjangan tersebut.

III.2 Analisis Kebutuhan

Berikut ini adalah penjabaran terkait kebutuhan-kebutuhan untuk membuat *dataset* yang baru.

III.2.1 Identifikasi Masalah Pengguna

Pengguna sistem ini adalah Steven (pembuat model) dan peneliti lain di bidang deteksi *deepfake*. Masalah yang dihadapi oleh para pengguna adalah:

1. Steven (pembuat model)
 - a. Steven membutuhkan data pelatihan yang memadai untuk membuat model yang *robust* terhadap video berkualitas rendah di Indonesia.
 - b. Modelnya mungkin akan *overfitting* pada video berkualitas tinggi dan gagal di skenario dunia nyata Indonesia.
2. Peneliti lainnya
 - a. Peneliti tidak memiliki *benchmark dataset* untuk menguji validitas model deteksi *deepfake* mereka dalam konteks Indonesia.

Untuk mencari solusi atas masalah-masalah tersebut, perlu disusun kebutuhan fungsional dan nonfungsional sistem yang diperlukan. Subbab berikut menjabarkan kebutuhan-kebutuhan tersebut.

III.2.2 Kebutuhan Fungsional

Berikut ini adalah Tabel III.1 yang berisi kebutuhan-kebutuhan fungsional yang dibutuhkan untuk menjawab masalah-masalah tersebut.

Tabel III.1 Kebutuhan Fungsional Dataset

Kode	Kebutuhan Fungsional	Deskripsi
F-01	Konteks Lokal	<i>Dataset</i> harus berisi video asli yang menampilkan wajah orang Indonesia yang beragam.
F-02	Representasi Etnis	<i>Dataset</i> harus merepresentasikan keragaman suku bangsa utama di Indonesia.
F-03	Teknik Relevan	<i>Dataset</i> harus berisi video palsu yang dibuat menggunakan teknik <i>deepfake</i> yang umum, seperti visual <i>deepfake</i> , audio <i>deepfake</i> , maupun <i>multimodal deepfake</i> .
F-04	Simulasi Kompresi	<i>Dataset</i> harus menyertakan versi video (asli dan palsu) yang telah disimulasikan efek kompresinya untuk meniru kualitas rendah di media sosial.
F-05	Pelabelan Jelas	Setiap video dalam <i>dataset</i> harus memiliki label yang jelas.
F-06	Metadata Lengkap	<i>Dataset</i> harus disertai <i>metadata</i> yang detail untuk setiap video palsu.
F-07	Keseimbangan Data	<i>Dataset</i> harus memiliki keseimbangan yang wajar antara jumlah video asli dan palsu, serta antara video berkualitas tinggi dan rendah.

III.2.3 Kebutuhan Nonfungsional

Berikut ini adalah Tabel III.2 yang berisi atribut-atribut mengenai bagaimana (*HOW*) sistem bekerja.

Tabel III.2 Kebutuhan Non Fungsional Dataset

Kode	Kebutuhan Non Fungsional	Penjelasan
NF-01	Relevansi	<i>Dataset</i> harus sangat relevan dengan masalah disinformasi <i>deepfake</i> di Indonesia.
NF-02	Keberagaman	<i>Dataset</i> harus beragam, tidak hanya dari segi etnis, tetapi juga pencahayaan, latar belakang, dan usia subjek.
NF-03	Validitas	Label harus 100% akurat. Proses validasi harus memastikan tidak ada kesalahan pelabelan.
NF-04	Realisme	Video berkualitas rendah yang dihasilkan harus secara akurat mencerminkan artefak kompresi yang ditemukan di platform nyata.

III.3 Analisis Pemilihan Solusi

Berikut ini adalah beberapa alternatif solusi yang diusulkan beserta metode dalam penentuan solusi.

III.3.1 Alternatif Solusi

Berikut ini adalah Tabel III.3 yang menampilkan beberapa alternatif solusi yang diajukan untuk memenuhi kebutuhan akan *dataset deepfake* berkualitas rendah di Indonesia.

Tabel III.3 Alternatif Solusi Dataset

Alternatif Solusi	Solusi
1	Mengambil <i>dataset</i> yang ada dan hanya menerapkan simulasi kompresi pada video-video tersebut.
2	Hanya mengumpulkan video <i>deepfake</i> yang sudah beredar di media sosial Indonesia.
3	Mengumpulkan video asli lokal, membuat <i>deepfake</i> sendiri, dan menerapkan kompresi secara sistematis.

III.3.2 Analisis Penentuan Solusi

Berikut ini adalah Tabel III.4 yang menampilkan beberapa alternatif solusi yang diajukan untuk memenuhi kebutuhan akan *dataset deepfake* berkualitas rendah di

Indonesia.

Tabel III.4 Analisis Penentuan Solusi Dataset

Kebutuhan Fungsional	Alternatif Solusi 1	Alternatif Solusi 2	Alternatif Solusi 3
F-01 (Konteks Lokal)	Tidak Terpenuhi	Terpenuhi	Terpenuhi
F-02 (Representasi Etnis)	Tidak Terpenuhi	Tidak Terkontrol	Terpenuhi
F-03 (Teknik Relevan)	Terpenuhi	Tidak Diketahui	Terpenuhi
F-04 (Simulasi Kompresi)	Terpenuhi	Kompresi Acak	Terpenuhi
F-05 (Pelabelan Jelas)	Terpenuhi	Tidak Terkontrol	Terpenuhi
F-06 (Metadata Lengkap)	Tidak Terpenuhi	Tidak Diketahui	Terpenuhi
F-07 (Keseimbangan Data)	Tergantung Dataset	Tidak Seimbang	Terpenuhi

Berdasarkan Tabel III.4, dapat disimpulkan bahwa alternatif solusi 3 (Mengumpulkan video asli lokal, membuat *deepfake* sendiri, dan menerapkan kompresi secara sistematis) adalah satu-satunya yang dapat memenuhi semua kebutuhan fungsional yang diidentifikasi. Solusi ini memberikan kontrol penuh atas konteks, jenis manipulasi, tingkat kompresi, dan pelabelan, yang sangat penting untuk tujuan penelitian.

BAB IV

DESAIN KONSEP SOLUSI

Ilustrasikan desain konsep solusi dalam bentuk model konseptual dan penjelasan secara ringkas, beserta perbedaannya dengan sistem saat ini. Ilustrasi harus dapat dibandingkan (*before and after*). Karena masih berupa proposal, bab ini hanya berisi gambar desain konsep solusi tersebut dan penjelasan perbandingannya dengan gambar sistem yang ada saat ini (yang tergambar di awal Bab III).

BAB V

RENCANA SELANJUTNYA

Jelaskan secara detail langkah-langkah rencana selanjutnya, hal-hal yang diperlukan atau akan disiapkan, dan risiko dan mitigasinya, yang meliputi:

1. Rencana implementasi, termasuk alat dan bahan yang diperlukan, lingkungan, konfigurasi, biaya, dan sebagainya.
2. Desain pengujian dan evaluasi, misalnya metode verifikasi dan validasi.
3. Analisis risiko dan mitigasi, misalnya tindakan selanjutnya jika ada yang tidak berjalan sesuai rencana.

DAFTAR PUSTAKA

- Alrashoud, Mubarak. 2025. "Deepfake video detection methods, approaches, and challenges". *Alexandria Engineering Journal*.
- Badan Pusat Statistik. 2012. *Kewarganegaraan, Suku Bangsa, Agama, dan Bahasa Sehari-hari Penduduk Indonesia: Hasil Sensus Penduduk 2010*. Technical report.
- Banerjee, S., S. K. Yadav, A. Dhara, dan M. Ajij. 2024. "A Survey: Deepfake and Current Technologies for Solutions". Dalam *The 2024 Sixth Doctoral Symposium on Intelligence Enabled Research (DoSIER 2024)*.
- Ciftci, Umur Aybars, İlke Demir, dan Lijun Yin. 2020. "FakeCatcher: Detection of Synthetic Portrait Videos using Biological Signals". *IEEE Transactions on Pattern Analysis and Machine Intelligence*.
- Croitoru, Florinel-Alin, dkk. 2024. *Deepfake Media Generation and Detection in the Generative AI Era: A Survey and Outlook*.
- Fernandes, Yoggy Arif, dan Yulia Fatma. 2025. "METODE DEEP LEARNING DALAM TEKNOLOGI DEEPPAKE: SYSTEMATIC LITERATURE REVIEW". *JATI (Jurnal Mahasiswa Teknik Informatika)*.
- Gebru, Timnit, Jamie Morgenstern, Briana Vecchione, Jennifer Wortman Vaughan, Hanna Wallach, Hal Daumé III, dan Kate Crawford. 2021. *Datasheets for Datasets*.
- Graupner, Hendrik, Mohammad Yeghaneh Abkenar, Lisa Schwetlick, Ralf Engbert, dan Christoph Meinel. 2025. "Behavior-Based Deepfake Detection: Leveraging Cognitive Response to Visual Face Perception". Dalam *Proceedings of the 18th International Joint Conference on Biomedical Engineering Systems and Technologies (BIOSTEC 2025)*.

Li, Y., dan S. Lyu. 2019. "Exposing DeepFake Videos By Detecting Face Warping Artifacts". Dalam *2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*.

Montibeller, Andrea, Dasara Shullani, Davide Baracchi, Alessandro Piva, dan Giulia Boato. 2025. "Bridging the Gap: A Framework for Real-World Video Deepfake Detection via Social Network Compression Emulation". Dalam *Proceedings of the 1st Deepfake Forensics Workshop: Detection, Attribution, Recognition, and Adversarial Challenges in the Era of AI-Generated Media (DFF '25)*.

Orr, Will, dan Kate Crawford. 2024. *Building Better Datasets: Seven Recommendations for Responsible Design from Dataset Creators*.

Sohan, Md Fahim, Mohammad Solaiman, dan Md Anwarul Hasan. 2023. "A survey on deepfake video detection datasets". *Indonesian Journal of Electrical Engineering and Computer Science*.

Zha, Daochen, Zaid Pervaiz Bhat, Kwei-Herng Lai, Fan Yang, Zhimeng Jiang, Shaochen Zhong, dan Xia Hu. 2023. *Data-centric Artificial Intelligence: A Survey*.